[redacted]

[redacted] **- A1 Cycle Ingénieur**

IIF.1105 - IF.2301 - Data Science

Rapport académique

Analyse de facteurs influençant le PSA chez des patients atteints d'un cancer de la prostate via l'apprentissage automatique

ACP, régression linéaire simple et multiple

Réalisé par : Angéline [redacted]

Année universitaire 2025 / 2026

Résumé

Ce rapport présente une analyse statistique complète d'un jeu de données médical relatif à la prostate. L'étude s'articule autour de trois axes principaux : une analyse descriptive initiale, une analyse en composantes principales (ACP) et une modélisation par régression linéaire. Les résultats montrent que la transformation logarithmique des variables améliore la régularité des distributions et facilite l'interprétation statistique. L'ACP met en évidence deux axes structurants expliquant une part importante de la variabilité des données. Enfin, la régression linéaire simple et multiple permet d'identifier les variables les plus associées au niveau de PSA, notamment le volume tumoral et le poids prostatique.

Table des matières

Résumé **i**

1 Introduction **1**

2 Analyse préliminaire : statistiques descriptives **2**

2.1 Question 1 — Combien y a-t-il d'observations ? Combien de variables ? Y a-t-il des valeurs manquantes ? 2

2.2 Question 2 — Statistiques descriptives et interprétation 2

2.3 Transformation logarithmique et interprétation 4

3 Analyse en composantes principales (ACP) **7**

3.1 Question théorique — Si deux variables sont parfaitement corrélées, faut-il garder les deux dans une PCA ? Et si elles sont complètement décorrélées ? 7

3.2 Question 1 — Variance de chaque variable et nécessité de standardiser . . . 7

3.3 Question 2 — Réalisation de la PCA et interprétation des deux premiers vecteurs de charge 8

3.4 Question 3 — Pourcentage de variance expliquée (PVE) et nombre de composantes à retenir 9

3.5 Question 4 — Scores, vecteurs de charge et cercle des corrélations 10

4 Régression linéaire **13**

4.1 Question théorique — Interprétation de R^2, intervalle de valeurs et relation avec r_1, r_2 13

5 Régression linéaire simple **14**

5.1 Question préliminaire — Corrélation entre la cible et les autres variables . 14

5.2 Question 1 — Quelle variable est la plus corrélée à `lpsa` ? 14

5.3 Question 2 — Estimation du modèle simple et interprétation de $\hat{\beta}_1$ 15

5.4 Question 3 — Expression générale de l'intervalle de confiance et calcul à 95 % 15

5.5 Question 4 — Test de pente nulle 15
5.6 Question 5 — Valeur de R^2 et interprétation 16

6 Sélection de variables pour la régression multiple 17
6.1 Question 1 — Best subset selection et choix du meilleur modèle 17
6.2 Question 2 — Combien de variables ont été retenues ? Lesquelles ? 18
6.3 Question 3 — Pourquoi utiliser $\bar{R}^2$ au lieu de R^2 ? 18
6.4 Question 4 — Coefficients estimés du modèle retenu et interprétation . . . 19
6.5 Question 5 — Test de pente nulle pour tous les coefficients sauf β_0 19
6.6 Question 6 — Prédiction pour un nouveau patient 20

7 Conclusion générale 21

Table des figures 22

Chapitre 1

Introduction

L'analyse statistique des données médicales occupe une place essentielle dans l'aide à la décision clinique et dans la compréhension des mécanismes pathologiques. Dans ce travail, nous étudions un jeu de données portant sur plusieurs caractéristiques liées à la prostate, avec un intérêt particulier pour le taux de *PSA* (*Prostate-Specific Antigen*), biomarqueur fréquemment utilisé dans l'évaluation du risque tumoral.

L'objectif de ce rapport est triple :

— décrire les principales caractéristiques du jeu de données ;

— résumer la structure de dépendance entre les variables à l'aide d'une analyse en composantes principales ;

— modéliser la variable `lpsa` à l'aide de régressions linéaires simple et multiple.

Le rapport adopte une démarche progressive, allant de l'exploration descriptive à la modélisation explicative.

Chapitre 2

Analyse préliminaire : statistiques descriptives

2.1 Question 1 — Combien y a-t-il d'observations ? Combien de variables ? Y a-t-il des valeurs manquantes ?

Le jeu de données contient **80 observations** et **6 variables quantitatives** : `vol`, `wht`, `age`, `bh`, `pc` et `psa`.

Aucune valeur manquante n'est présente dans le fichier, ce qui permet de mener l'analyse sans traitement des données manquantes.

2.2 Question 2 — Statistiques descriptives et interprétation

Les statistiques descriptives sur les variables brutes montrent une forte hétérogénéité d'échelle entre les variables. Par exemple :

- `vol` : moyenne = 6.77, médiane = 3.57, maximum = 45.65 ;
- `wht` : moyenne = 41.58, médiane = 38.30, maximum = 111.95 ;
- `age` : moyenne = 63.61, médiane = 65, maximum = 79 ;
- `bh` : moyenne = 2.69, médiane = 1.30, maximum = 10.24 ;
- `pc` : moyenne = 2.19, médiane = 0.45, maximum = 18.25 ;
- `psa` : moyenne = 25.47, médiane = 14.40, maximum = 265.85.

L'écart entre moyenne et médiane, particulièrement marqué pour `vol`, `pc` et surtout `psa`, indique des distributions fortement asymétriques à droite. Cela suggère la présence de quelques patients présentant des valeurs biologiques ou pathologiques très élevées, ce qui est fréquent dans les jeux de données médicaux. En particulier, la variable `psa` présente une dispersion très importante, avec un écart-type de 44.31, nettement supérieur à la médiane. Cette observation justifie la transformation logarithmique demandée dans le sujet.

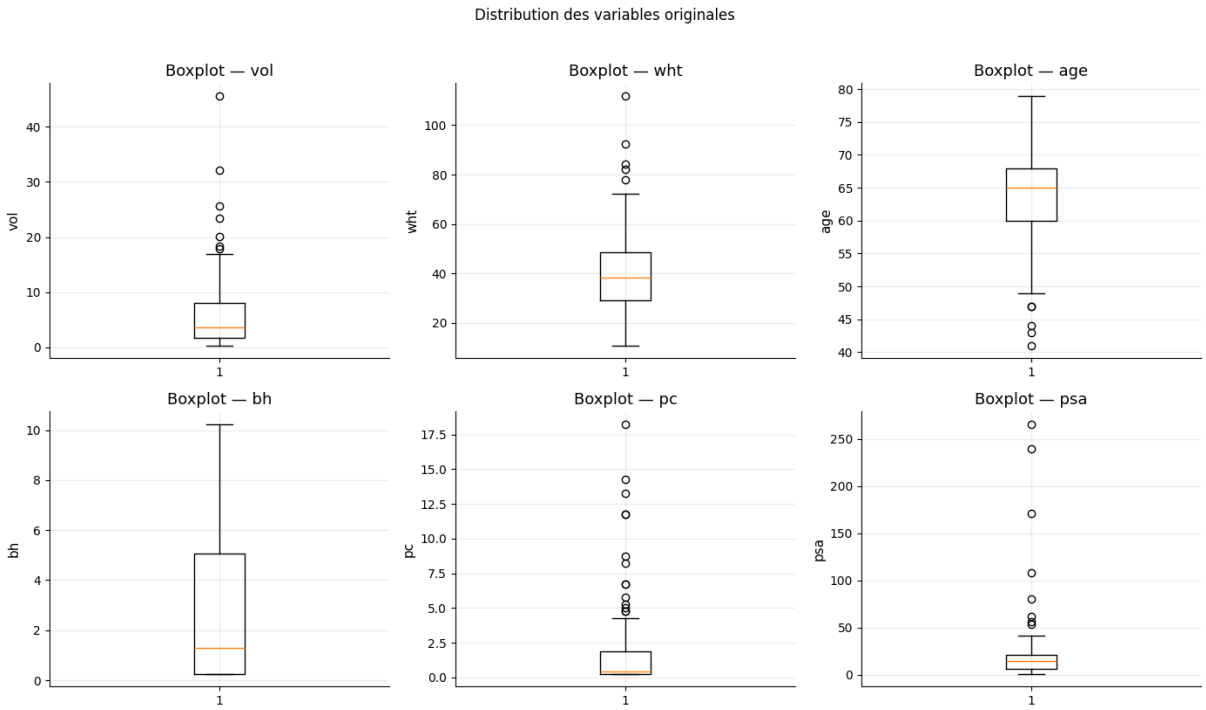

FIGURE 2.1 – **Boxplots des variables originales**

Interprétation

Les boxplots mettent en évidence une forte asymétrie dans plusieurs variables, notamment `psa`, `vol` et `pc`, avec la présence de nombreuses valeurs extrêmes. La variable `age` est quant à elle plus symétrique. Ces observations confirment que les variables ne suivent pas une distribution normale et justifient l'utilisation d'une transformation logarithmique pour améliorer l'analyse.

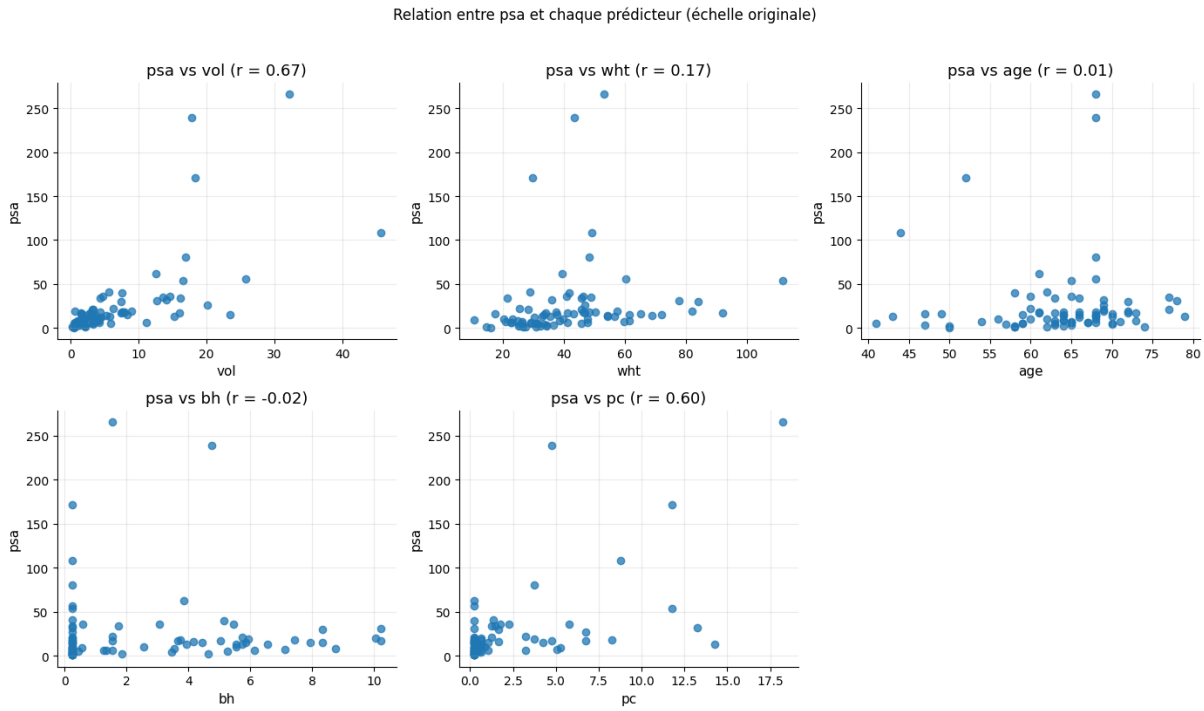

FIGURE 2.2 – **Relation entre `psa` et chaque prédicteur (échelle originale)**

Interprétation

Les nuages de points entre la variable cible `psa` et les différentes variables explicatives montrent que certaines relations semblent positives, notamment avec `vol` et `pc`. En revanche, les relations avec `age` et `bh` apparaissent très faibles. On observe également une forte concentration de points dans certaines zones, ce qui suggère une distribution asymétrique des données et motive l'utilisation d'une transformation logarithmique.

2.3 Transformation logarithmique et interprétation

Conformément à l'énoncé, toutes les variables sauf `age` ont été transformées par logarithme :

`lvol`, `lwht`, `lbh`, `lpc`, `lpsa`.

Après transformation, les distributions deviennent beaucoup plus régulières. Les nuages de points entre `lpsa` et les autres variables transformées sont moins concentrés dans quelques petites régions et mettent mieux en évidence les tendances linéaires.

D'un point de vue statistique, cette transformation :

— réduit l'asymétrie des variables ;

— diminue l'effet des valeurs extrêmes.

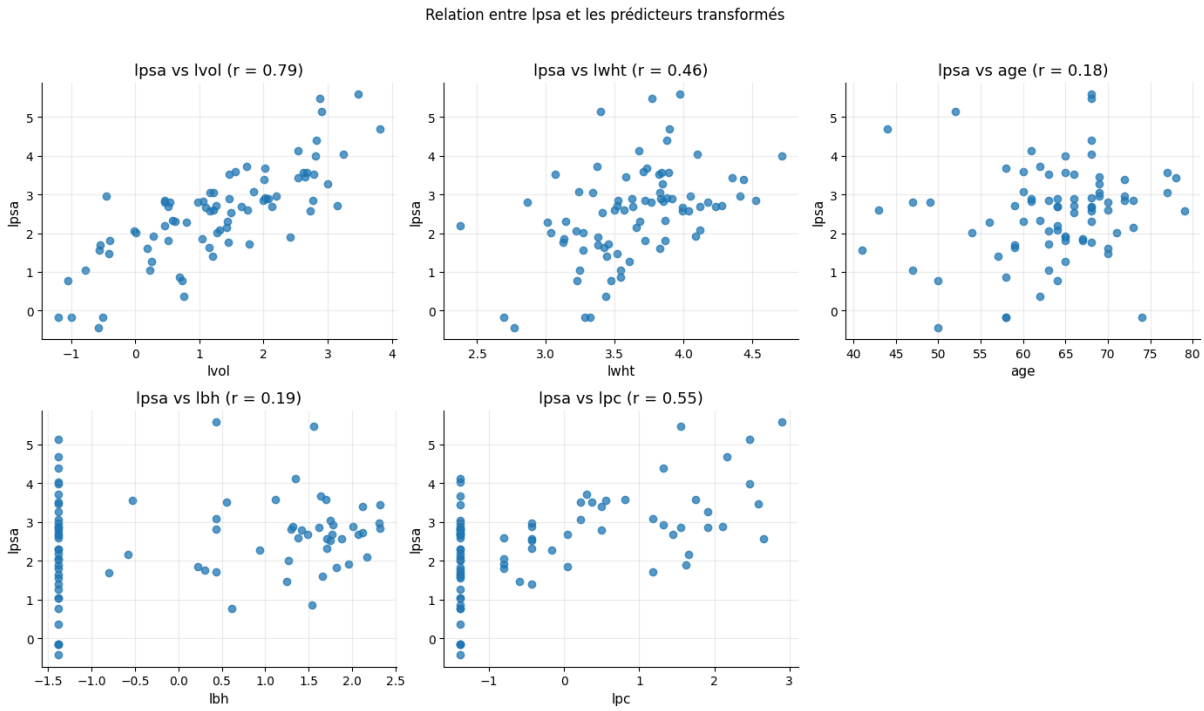

FIGURE 2.3 – **Relation entre `lpsa` et les prédicteurs transformés**

Interprétation

Après transformation logarithmique des variables (excepté `age`), les relations entre `lpsa` et les prédicteurs apparaissent plus linéaires. La corrélation entre `lpsa` et `lvol` devient particulièrement forte, ce qui suggère que `lvol` est un bon prédicteur du niveau de PSA. Cette transformation permet donc de mieux satisfaire les hypothèses du modèle linéaire.

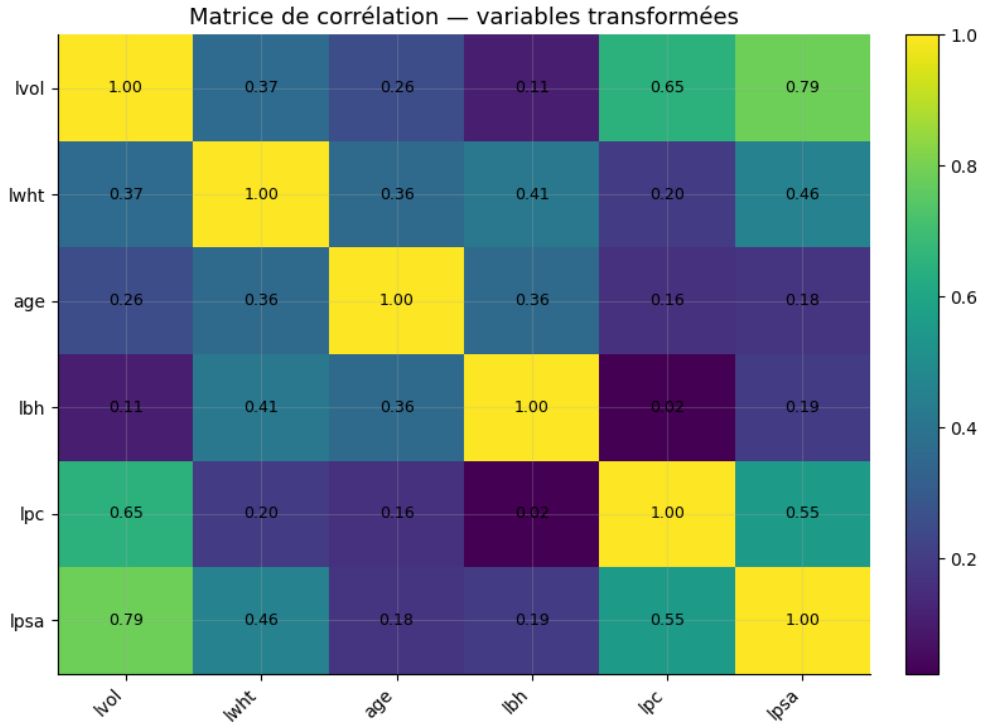

FIGURE 2.4 – **Matrice de corrélation des variables transformées**

Interprétation

La matrice de corrélation montre que la variable la plus fortement corrélée avec `lpsa` est `lvol` (corrélation ≈ 0.79), suivie par `lpc` (≈ 0.55) et `lwht` (≈ 0.46). Les variables `age` et `lbh` présentent des corrélations faibles avec la variable cible. Ainsi, `lvol` est retenue comme meilleure variable explicative pour la régression simple.

Les statistiques descriptives sur les variables transformées montrent notamment :

- `lvol` : variance = 1.409 ;
- `lwht` : variance = 0.185 ;
- `age` : variance = 62.367 ;
- `lbh` : variance = 2.163 ;
- `lpc` : variance = 1.868 ;
- `lpsa` : variance = 1.444.

On observe donc que la transformation logarithmique réduit fortement la dispersion de certaines variables, mais `age` reste sur une échelle très différente.

Chapitre 3

Analyse en composantes principales (ACP)

3.1 Question théorique — Si deux variables sont parfaitement corrélées, faut-il garder les deux dans une PCA ? Et si elles sont complètement décorrélées ?

Si deux variables sont parfaitement corrélées, il n'est pas pertinent de conserver les deux dans une ACP. En effet, elles apportent exactement la même information ; dans un tel cas, une composante principale peut pratiquement résumer cette information commune à elle seule.

À l'inverse, si deux variables sont non corrélées, chacune apporte une information distincte. Les conserver toutes les deux peut donc être pertinent, car elles décrivent des dimensions différentes de la variabilité des données.

Autrement dit, l'ACP est particulièrement utile lorsqu'il existe des dépendances linéaires entre variables, car elle permet de résumer cette information corrélée dans un plus petit nombre d'axes.

3.2 Question 1 — Variance de chaque variable et nécessité de standardiser

Les variances des variables transformées sont :

— `lvol` : 1.409 ;

— `lwht` : 0.185 ;

— `age` : 62.367 ;

— `lbh` : 2.163 ;

— `lpc` : 1.868 ;

— `lpsa` : 1.444.

Ces valeurs montrent un écart très important entre `age` et les autres variables. Comme l'ACP est sensible à l'échelle des variables, il est nécessaire de standardiser les variables avant de réaliser l'analyse.

Sans standardisation, la variable `age` dominerait mécaniquement les premières composantes principales uniquement à cause de sa variance plus élevée, et non parce qu'elle porte plus d'information structurelle.

3.3 Question 2 — Réalisation de la PCA et interprétation des deux premiers vecteurs de charge

L'ACP a donc été réalisée sur les variables transformées centrées-réduites.

Les deux premiers vecteurs de charge sont approximativement :

Première composante principale (PC1)

— `lvol` : 0.514

— `lwht` : 0.396

— `age` : 0.291

— `lbh` : 0.242

— `lpc` : 0.418

— `lpsa` : 0.511

Cette première composante oppose peu les variables entre elles : toutes les charges sont positives. Elle représente donc un axe général de sévérité / intensité pathologique, où un patient ayant un grand volume tumoral, un poids prostatique élevé, une pénétration capsulaire importante et un PSA élevé obtient un score élevé sur PC1.

Deuxième composante principale (PC2)

— `lvol` : -0.290

— `lwht` : 0.361

— `age` : 0.459

— `lbh` : 0.612

— `lpc` : -0.392

— `lpsa` : -0.217

Cette seconde composante oppose principalement :

— d'un côté `age`, `lbh` et `lwht`,

— de l'autre `lvol`, `lpc` et plus légèrement `lpsa`.

On peut donc interpréter PC2 comme un axe distinguant plutôt une composante liée à l'hypertrophie bénigne / âge / poids prostatique d'une composante davantage liée à l'agressivité tumorale.

3.4 Question 3 — Pourcentage de variance expliquée (PVE) et nombre de composantes à retenir

Les pourcentages de variance expliquée par chaque composante sont :

— PC1 : 46.47 %

— PC2 : 22.99 %

— PC3 : 11.72 %

— PC4 : 9.16 %

— PC5 : 6.56 %

— PC6 : 3.11 %

La variance cumulée expliquée est donc :

— PC1 + PC2 : 69.46 %

— PC1 + PC2 + PC3 : 81.18 %

— PC1 + PC2 + PC3 + PC4 : 90.34 %

Un choix raisonnable consiste à retenir **2 composantes** pour une représentation graphique synthétique et interprétable, car elles résument déjà près de 70 % de la variabilité totale. Si l'on cherche une meilleure restitution de l'information pour une analyse plus fine, **3 composantes** constituent aussi un bon compromis avec plus de 81 % de variance expliquée.

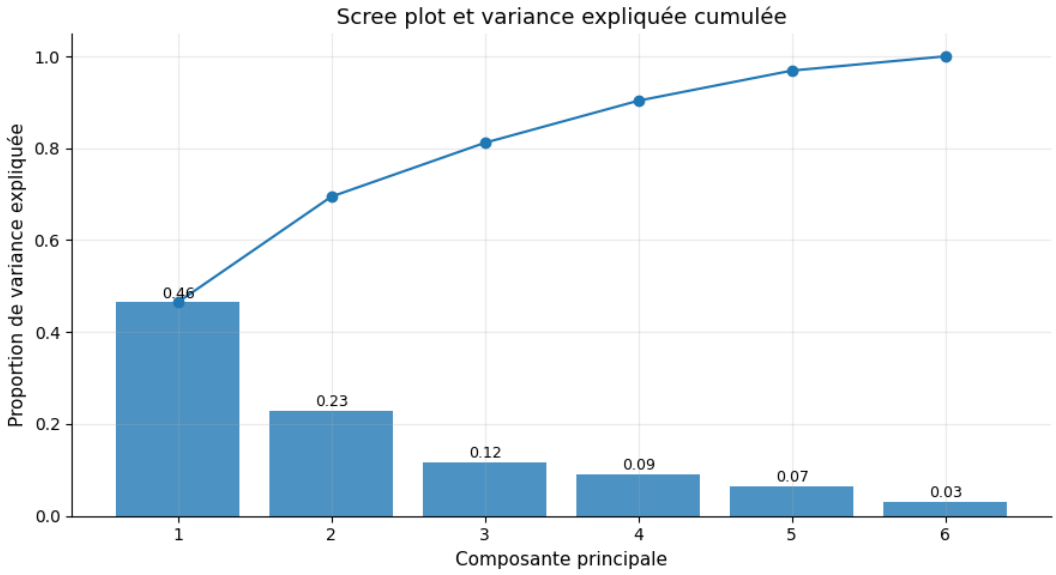

FIGURE 3.1 – **Scree plot et variance expliquée cumulée**

Interprétation

Le scree plot montre que la première composante principale explique environ 46 % de la variance, et les deux premières environ 69 %. La variance expliquée cumulée augmente rapidement puis se stabilise, ce qui suggère qu'un petit nombre de composantes suffit à représenter l'essentiel de l'information. Il est raisonnable de retenir les deux ou trois premières composantes.

3.5 Question 4 — Scores, vecteurs de charge et cercle des corrélations

L'analyse du cercle des corrélations confirme que :

— `lvol` et `lpsa` sont très fortement corrélées à PC1 ;

— `lpc` est aussi nettement alignée avec PC1 ;

— `lbh`, `age` et `lwht` contribuent davantage à PC2.

Les corrélations des variables avec les deux premières composantes sont approximativement :

— `lvol` : (PC1 = 0.864, PC2 = -0.343)

— `lwht` : (PC1 = 0.665, PC2 = 0.426)

— `age` : (PC1 = 0.488, PC2 = 0.542)

— `lbh` : (PC1 = 0.406, PC2 = 0.723)

— `lpc` : (PC1 = 0.703, PC2 = -0.463)

— `lpsa` : (PC1 = 0.859, PC2 = -0.257)

Cela suggère que `lpsa` est surtout portée par le même axe que `lvol` et `lpc`, alors que `lbh` et `age` décrivent un mécanisme partiellement distinct. Le nuage des individus projetés sur le plan principal doit donc montrer une gradation de sévérité sur l'axe 1, et une différenciation plus structurelle ou physiologique sur l'axe 2.

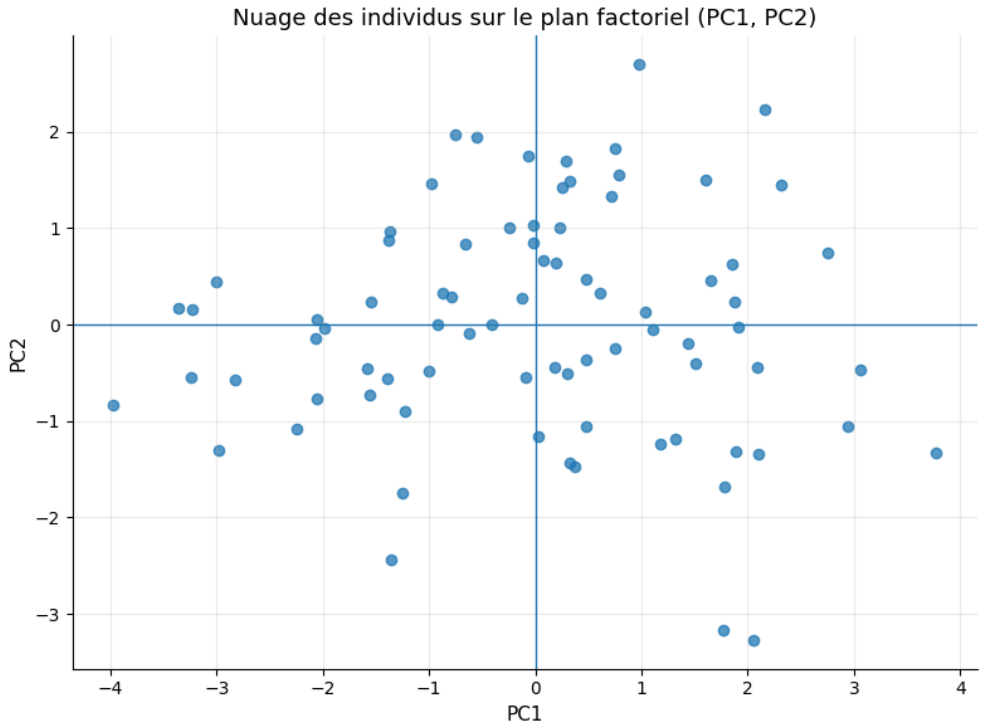

FIGURE 3.2 – **Nuage des individus sur le plan factoriel (PC1, PC2)**

Interprétation

Le nuage des individus projetés sur les deux premières composantes principales ne révèle pas de groupes clairement distincts. Les observations sont réparties de manière relativement homogène, ce qui suggère l'absence de structure de clusters évidente dans les données.

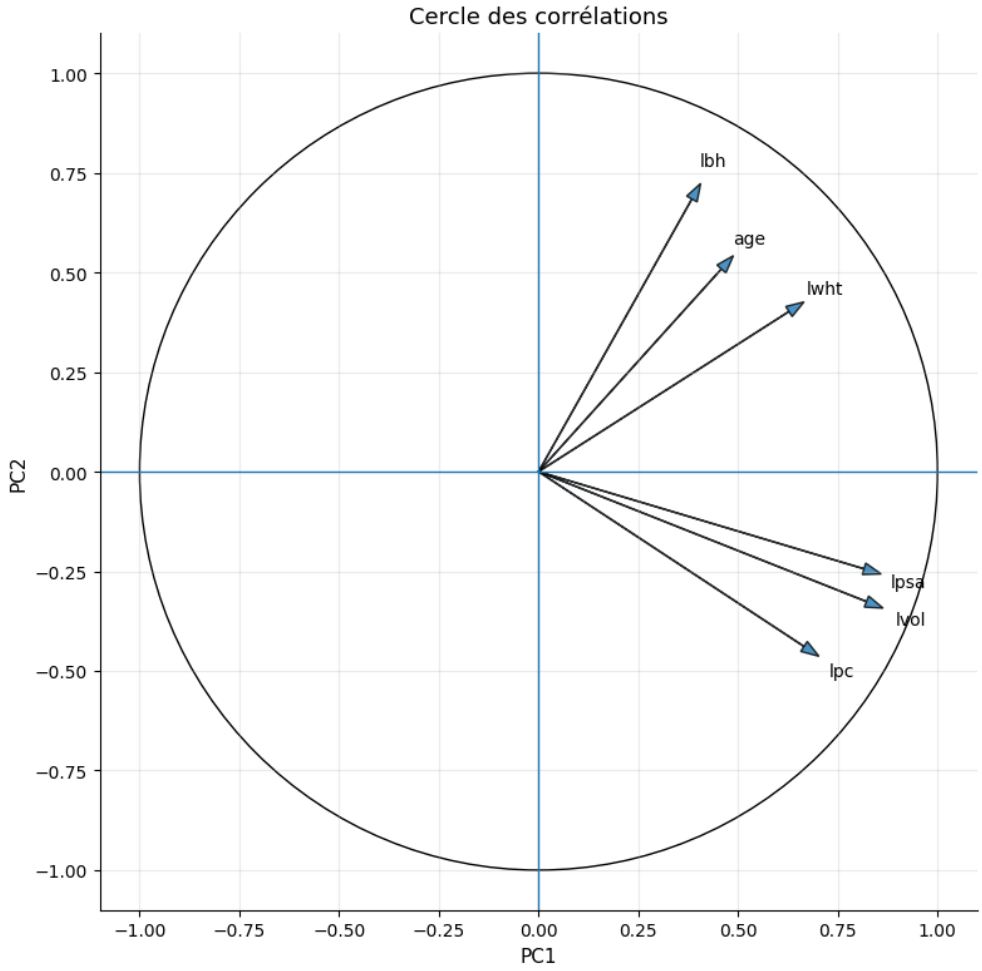

FIGURE 3.3 – **Cercle des corrélations**

Interprétation

Le cercle des corrélations montre que `lpsa`, `lvol` et `lpc` sont fortement corrélées et contribuent principalement à la première composante principale. Les variables `age` et `lbh` contribuent davantage à la deuxième composante. Cela indique que la variabilité des données est principalement expliquée par des facteurs liés au volume et à la progression du cancer.

Chapitre 4

Régression linéaire

4.1 Question théorique — Interprétation de R^2, intervalle de valeurs et relation avec r_1, r_2

Le coefficient de détermination R^2 mesure la proportion de la variance de Y expliquée par le modèle de régression. Il prend des valeurs dans l'intervalle $[0, 1]$ lorsqu'un intercept est inclus dans le modèle classique.

— $R^2 = 0$ signifie que le modèle n'explique rien de la variabilité de Y ;

— $R^2 = 1$ signifie que le modèle explique parfaitement Y.

Avec deux variables explicatives X_1 et X_2, R^2 ne dépend pas uniquement de r_1 et r_2, les corrélations de Y avec X_1 et X_2, mais aussi de la corrélation r_{12} entre X_1 et X_2. En général :

$$R^2 = \frac{r_1^2 + r_2^2 - 2r_1r_2r_{12}}{1 - r_{12}^2}.$$

Dans le cas particulier où X_1 et X_2 sont non corrélées, on obtient :

$$R^2 = r_1^2 + r_2^2.$$

Cette formule montre bien que l'information apportée par deux prédicteurs dépend aussi de leur redondance.

Chapitre 5

Régression linéaire simple

5.1 Question préliminaire — Corrélation entre la cible et les autres variables

Les corrélations entre `lpsa` et les autres variables transformées sont :

- avec `lvol` : 0.786
- avec `lpc` : 0.555
- avec `lwht` : 0.456
- avec `lbh` : 0.193
- avec `age` : 0.176

La variable la plus corrélée à `lpsa` est donc `lvol`. Ce résultat est cohérent médicalement : un volume tumoral plus important est associé à un PSA plus élevé.

5.2 Question 1 — Quelle variable est la plus corrélée à `lpsa` ?

La variable la plus corrélée à `lpsa` est `lvol`, avec un coefficient de corrélation linéaire de 0.786. Cette corrélation est relativement forte et positive.

5.3 Question 2 — Estimation du modèle simple et interprétation de $\hat{\beta}_1$

On ajuste le modèle :

$$lpsa = \beta_0 + \beta_1 lvol + \varepsilon.$$

Les estimateurs obtenus sont :

$$\hat{\beta}_0 = 1.482, \qquad \hat{\beta}_1 = 0.796.$$

Le modèle estimé est donc :

$$\widehat{lpsa} = 1.482 + 0.796\, lvol.$$

L'interprétation de $\hat{\beta}_1$ est la suivante : lorsque `lvol` augmente d'une unité, la variable `lpsa` augmente en moyenne de 0.796 unité, toutes choses égales par ailleurs. Comme il s'agit de logarithmes, cela traduit une relation multiplicative entre le volume tumoral et le PSA.

5.4 Question 3 — Expression générale de l'intervalle de confiance et calcul à 95 %

L'intervalle de confiance bilatéral de niveau $1-\alpha$ pour β_1 est :

$$\hat{\beta}_1 \pm t_{n-2,1-\alpha/2}\, SE(\hat{\beta}_1).$$

Dans notre cas, l'intervalle de confiance à 95 % pour β_1 est :

$$[0.654\,;\, 0.937].$$

Comme cet intervalle ne contient pas 0, il y a une forte évidence statistique d'un effet positif de `lvol` sur `lpsa`.

5.5 Question 4 — Test de pente nulle

On teste :

$$H_0 : \beta_1 = 0 \qquad \text{contre} \qquad H_1 : \beta_1 \neq 0.$$

Le test donne :

— statistique de Student : $t = 11.221$

— p-value < 0.001

On rejette donc très nettement H_0. La pente est significativement non nulle, ce qui signifie que `lvol` a un impact statistiquement significatif sur `lpsa`.

5.6 Question 5 — Valeur de R^2 et interprétation

Le coefficient de détermination du modèle simple vaut :

$$R^2 = 0.617.$$

Cela signifie que 61.7 % de la variabilité de `lpsa` est expliquée par `lvol` seul. C'est un résultat déjà substantiel pour un modèle à une seule variable. Néanmoins, près de 38.3 % de la variabilité reste inexpliquée, ce qui suggère qu'un modèle multiple pourrait être préférable pour améliorer la prédiction.

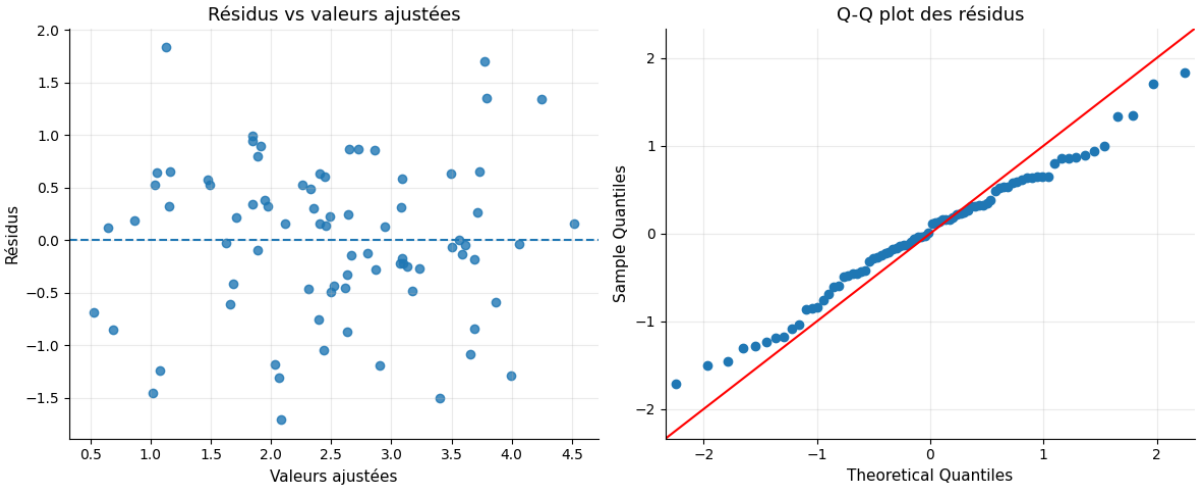

FIGURE 5.1 – **Diagnostics de la régression simple : résidus et Q-Q plot**

Interprétation

Le graphique des résidus en fonction des valeurs ajustées ne montre pas de structure particulière, les résidus étant répartis de manière aléatoire autour de zéro. Cela suggère que l'hypothèse de linéarité est raisonnablement respectée. Le Q-Q plot indique que les résidus suivent globalement une distribution normale, malgré de légères déviations aux extrémités. Ainsi, les hypothèses du modèle de régression linéaire semblent globalement satisfaites.

Chapitre 6

Sélection de variables pour la régression multiple

6.1 Question 1 — Best subset selection et choix du meilleur modèle

Toutes les combinaisons possibles de 1 à 5 prédicteurs ont été testées, comme demandé dans l'énoncé.

Le modèle qui maximise le coefficient de détermination ajusté $\bar{R}^2$ est :

$$lpsa \sim lvol + lwht + age + lpc$$

avec :

$$\bar{R}^2 = 0.644.$$

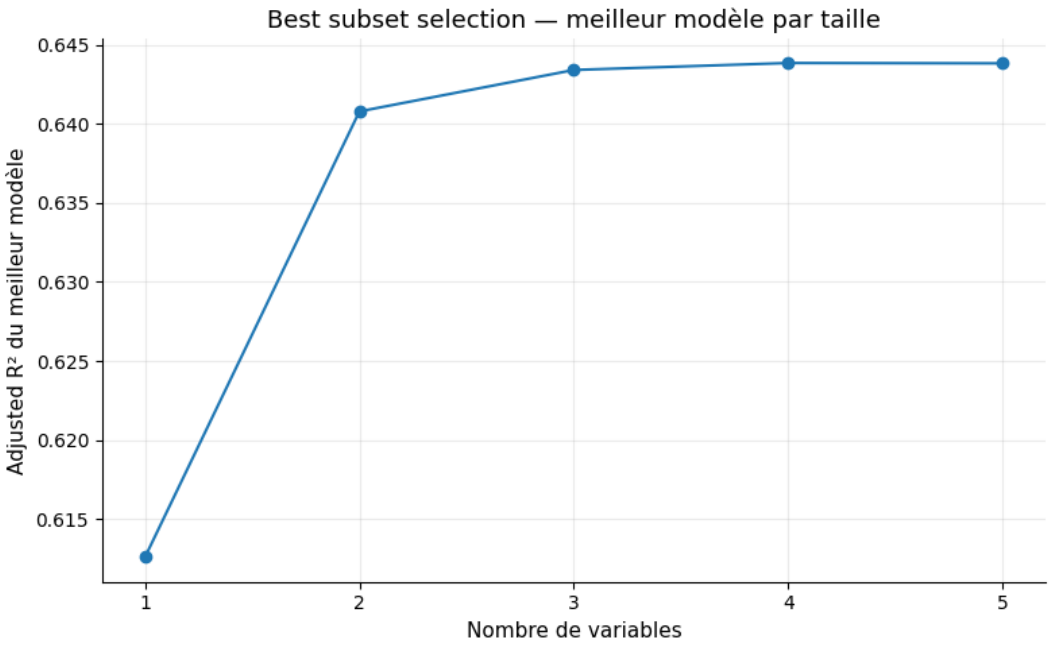

FIGURE 6.1 – **Sélection du meilleur modèle par $\bar{R}^2$ ajusté**

Interprétation

L'évolution du coefficient de détermination ajusté montre que celui-ci augmente rapidement lorsque l'on passe de 1 à 2 variables, puis se stabilise. Le meilleur modèle correspond à celui ayant le plus grand R^2 ajusté, ce qui permet d'équilibrer qualité d'ajustement et complexité du modèle. Cela justifie la sélection d'un modèle avec un nombre limité de variables explicatives.

6.2 Question 2 — Combien de variables ont été retenues ? Lesquelles ?

Le meilleur modèle, au sens du $\bar{R}^2$, retient **4 variables** :

- `lvol`
- `lwht`
- `age`
- `lpc`

La variable `lbh` n'est donc pas conservée dans le meilleur sous-modèle.

6.3 Question 3 — Pourquoi utiliser $\bar{R}^2$ au lieu de R^2 ?

Le coefficient R^2 augmente ou reste stable quand on ajoute des variables, même si ces variables n'apportent pas de véritable pouvoir explicatif. Il favorise donc artificiellement

les modèles plus complexes.

En revanche, le coefficient ajusté $\bar{R}^2$ pénalise l'ajout de prédicteurs inutiles. Il est donc plus approprié pour comparer des modèles ayant des nombres de variables différents, car il cherche un compromis entre qualité d'ajustement et parcimonie.

6.4 Question 4 — Coefficients estimés du modèle retenu et interprétation

Le modèle retenu est :

$$lpsa = \beta_0 + \beta_1 lvol + \beta_2 lwht + \beta_3 age + \beta_4 lpc + \varepsilon.$$

Les coefficients estimés sont :

$$\hat{\beta}_0 = 0.252, \quad \hat{\beta}_1 = 0.675, \quad \hat{\beta}_2 = 0.632, \quad \hat{\beta}_3 = -0.014, \quad \hat{\beta}_4 = 0.081.$$

Le modèle estimé est donc :

$$\widehat{lpsa} = 0.252 + 0.675\, lvol + 0.632\, lwht - 0.014\, age + 0.081\, lpc.$$

Interprétation.

- `lvol` a l'effet positif le plus marqué : à âge, poids prostatique et pénétration capsulaire fixés, une hausse de `lvol` est associée à une hausse de `lpsa` ;
- `lwht` a aussi un effet positif notable ;
- `age` a un coefficient légèrement négatif, mais faible ;
- `lpc` a un effet positif faible.

Le coefficient de détermination du modèle est :

$$R^2 = 0.662.$$

Le modèle explique donc 66.2 % de la variabilité de `lpsa`. Le gain par rapport au modèle simple est réel, mais modéré : on passe de 61.7 % à 66.2 %.

6.5 Question 5 — Test de pente nulle pour tous les coefficients sauf β_0

Les tests individuels donnent :

- `lvol` : p-value < 0.001, significatif ;

— `lwht` : p-value = 0.004, significatif ;

— `age` : p-value = 0.209, non significatif au seuil de 5 % ;

— `lpc` : p-value = 0.299, non significatif au seuil de 5 %.

On conclut donc que, dans ce modèle, seuls `lvol` et `lwht` ont un effet statistiquement significatif au seuil de 5 %. Les variables `age` et `lpc` participent au meilleur sous-modèle en termes de $\bar{R}^2$, mais leurs coefficients individuels ne sont pas significatifs. Cela peut refléter soit un effet faible, soit une redondance partielle avec les autres variables.

6.6 Question 6 — Prédiction pour un nouveau patient

On considère les valeurs :

$$vol = 7.2, \quad wht = 22, \quad bh = 1.5, \quad pc = 0.26, \quad age = 67.$$

Le modèle sélectionné utilise `lvol`, `lwht`, `age` et `lpc`, donc on transforme d'abord :

$$lvol = \log(7.2), \qquad lwht = \log(22), \qquad lpc = \log(0.26), \qquad age = 67.$$

La prédiction obtenue est :

$$\widehat{lpsa} = 2.489.$$

En revenant à l'échelle initiale :

$$\widehat{psa} = e^{2.489} \approx 12.04.$$

La valeur prédite du niveau de PSA pour ce patient est donc d'environ **12.0**.

Chapitre 7

Conclusion générale

Cette étude met en évidence plusieurs résultats importants.

Premièrement, les variables brutes présentent une forte asymétrie, surtout pour `psa`, `vol` et `pc`, ce qui justifie pleinement la transformation logarithmique imposée dans le sujet.

Deuxièmement, l'ACP réalisée sur les variables transformées et standardisées montre qu'une grande partie de l'information peut être résumée par deux axes principaux. Le premier axe traduit essentiellement une dimension de sévérité tumorale, fortement liée à `lvol`, `lpc` et `lpsa`, tandis que le second oppose davantage les caractéristiques associées au poids prostatique, à l'âge et à l'hyperplasie bénigne.

Troisièmement, la régression linéaire simple montre que `lvol` est la variable la plus liée à `lpsa`, avec une corrélation de 0.786 et un modèle expliquant 61.7 % de la variance de la réponse.

Enfin, la sélection de variables par *best subset selection* conduit à un modèle multiple à 4 variables (`lvol`, `lwht`, `age`, `lpc`) expliquant 66.2 % de la variance de `lpsa`. En pratique, les effets les plus robustes sont ceux de `lvol` et `lwht`, qui apparaissent statistiquement significatifs.

Dans l'ensemble, cette analyse confirme que le niveau de PSA est principalement associé au volume tumoral, mais qu'il dépend aussi, dans une moindre mesure, d'autres caractéristiques anatomiques ou cliniques, en particulier le poids prostatique.

Table des figures

2.1 **Boxplots des variables originales** 3
2.2 **Relation entre `psa` et chaque prédicteur (échelle originale)** 4
2.3 **Relation entre `lpsa` et les prédicteurs transformés** 5
2.4 **Matrice de corrélation des variables transformées** 6

3.1 **Scree plot et variance expliquée cumulée** 10
3.2 **Nuage des individus sur le plan factoriel (PC1, PC2)** 11
3.3 **Cercle des corrélations** 12

5.1 **Diagnostics de la régression simple : résidus et Q-Q plot** 16

6.1 **Sélection du meilleur modèle par $\bar{R}^2$ ajusté** 18